



정윤서

✉ jys0615234@gmail.com

☎ 01024130615 | 📅 2000년생

저는 Python/FastAPI를 주력으로 Java/Spring Boot까지 다루며, 데이터베이스 설계부터 AI 연동, 인프라 구성까지 백엔드 전반을 직접 설계하고 운영한 경험이 있습니다. 단순히 동작하는 코드를 넘어, 실제 운영 환경에서 신뢰성 있게 작동하는 시스템을 만드는 데 집중해왔습니다.

MCP 기반 AI 에이전트 시스템을 단독으로 설계·구현하고, LDI LAB 학부연구생으로 오픈소스 LLM 파인튜닝 연구를 수행하며 AI 백엔드 개발 전반에 걸친 경험을 쌓았습니다. FastAPI와 Spring Boot 이기종 서버 통합, Redis 멀티레이어 캐싱, Elasticsearch 기반 Observability 파이프라인 구축까지, 설계 단계부터 운영 단계까지 직접 부딪히며 만들어왔습니다.

에러 로그 하나도 허투루 넘기지 않고, 문제의 원인을 숫자로 정의한 뒤 끝을 봐야 직성이 풀리는 성격입니다. 러닝 동아리에서 10km부터 시작해 풀코스를 완주한 것처럼, 한번 시작한 일은 반드시 끝에 도달합니다.

개발은 동작하게 만드는 것이 아니라 운영되게 만드는 것이라고 생각합니다. 백엔드와 AI 사이의 연결고리를 설계하고, 그 시스템이 실제 사용자 앞에서 흔들리지 않도록 만드는 개발자가 되고 싶습니다.

기술 스택

Python

FastAPI

Java

Spring Boot

PostgreSQL

Redis

Elasticsearch

Docker

Amazon EC2

AZURE

GitHub Actions

Git

GitHub

학력

○ 2026.08 졸업 예정

대학교(4년) | **경희대학교**

컴퓨터공학과

3.75 / 4.5

○ 2021.02 중퇴

대학교(4년) | **경기대학교**

컴퓨터공학부

3.82 / 4.5

프로젝트

○ 2025.09 - 2025.12

Agent KHU

MCP 기반 AI 캠퍼스 정보 시스템

Python

FastAPI

Redis

PostgreSQL

Elasticsearch

Docker

1. 프로젝트 소개

FastAPI, MCP, Elasticsearch를 활용해 경희대 학생이 자연어로 캠퍼스 정보를 조회할 수 있는 AI Agent 기반 통합 정보 웹 시스템. MCP 마이크로서비스 6개 + Hybrid LLM/SLM 라우팅 + Redis 멀티레이어 캐싱 + Observability 파이프라인으로 구성된 단독 프로젝트.

2. 역할

- 전체 시스템 아키텍처 설계 및 구현 (기획·설계·개발·운영 단독 수행)
- MCP 마이크로서비스 6개 설계 및 Claude AI Agent 라우팅 구조 구현
- Docker Compose 기반 7개 서비스 인프라 구성 및 Prometheus + Grafana 모니터링

3. 기여한 점

- cProfile로 MCP 콜드스타트(12초)를 병목으로 정량 진단 → 영구 세션 풀 설계 및 Graceful Degradation 구조 구현으로 응답 시간 16.6초 → 5.5초(67% 단축), 에러율 15% → 2%
- Question Classifier 기반 3단계 Hybrid 라우팅(RAG → LLM → Fallback) 설계로 전체 질의 62%를 LLM 없이 처리, Simple 질의 응답시간 100~200ms 달성
- Tool별 데이터 변경 주기 분석해 차등 TTL 캐싱 전략 설계(24시간~NO_CACHE), 캐시 히트율 95% · MCP 서버 부하 40% 감소
- Elasticsearch에 12개 필드 인덱싱하는 Observability 파이프라인 구축, 라우팅 분포 및 응답 latency 실시간 추적

저장소 링크

· <https://github.com/jys0615/agent-khu>

○ 2025.03 - 2025.06

EPiC

졸업요건 자동 진단 시스템

Python

FastAPI

Java

Spring Boot

Redis

MongoDB

JSON Web Token

Docker

AZURE

GitHub Actions

1. 프로젝트 소개

성적증명서 PDF 업로드만으로 졸업요건 충족 여부를 자동 진단하고 AI 기반 커리큘럼 추천을 제공하는 웹 서비스. FastAPI(AI 서버) + Spring Boot(백엔드) 이기종 서버 통합 구조로 3주 내 완성. 세모톤 최우수상 수상(2025.04.06).

2. 역할

- FastAPI AI 서버(PDF 분석·GPT 호출)와 Spring Boot 백엔드(인증·데이터 관리) 통합 담당
- GitHub Actions + Docker Compose 기반 Azure 자동 배포 파이프라인 구성

3. 기여한 점

- Spring Boot를 단일 진입점으로 설계하고 `BodyInserters.fromMultipartData()`로 멀티파트 파일을 FastAPI로 중계하는 이기종 서버 통합 파이프라인 구축, 세모톤 3주 내 완성 및 최우수상 수상
- RestTemplate → WebClient 전환으로 이기종 서버 간 비동기 논블로킹 처리 전환, 코드량 59줄 → 30줄 감소 · Nginx Gzip 압축 적용으로 응답 크기 40% 감소
- 데이터 성격별 Redis TTL 3단계 설계(인증 토큰 10분 / 추천 결과 6시간 / 졸업 분석 24시간)로 커리큘럼 추천 응답시간 5.8초 → 0.07초(99% 단축)
- session-id 헤더 기반 사용자별 Redis 독립 세션 구성(TTL 30분)으로 전역 변수 공유 문제 및 서버 재시작 시 세션 소멸 문제 해결

저장소 링크

· <https://github.com/jys0615/EPiC>

○ 2025.07 - 2025.08

민들레

동대문구 통합 민원 자동화 플랫폼

Spring Boot

FastAPI

Node.js

Next.js

PostgreSQL

1. 프로젝트 소개

민원 내용을 입력하면 채널 추천부터 AI 초안 생성, 민원 사이트 자동 입력까지 원스톱으로 처리하는 동대문구 특화 민원 자동화 플랫폼. Spring Boot · FastAPI · Node.js · Next.js 4개 이기종

서버 통합 구조.

2. 역할

- 4개 이기종 서버 오케스트레이션 아키텍처 설계 및 Spring Boot 백엔드 개발
- 다단계 민원 처리 파이프라인 설계 (민원 입력 → 채널 분류 → AI 개선 → 북마크릿 생성 → 반환)

3. 기여한 점

- Spring Boot를 단일 오케스트레이터로 설계하고 각 단계 완료 직후 DB 커밋하는 방식으로 이기종 서버 간 통신 실패 시에도 완료 단계 보존, DB 정합성 100% 확보
- ComplaintData 엔티티에 aiImprovedContent 상태 플래그 도입(NULL → 개선본)으로 AI 처리 실패 시 원본 폴백 구조 구현, 민원 데이터 손실 방지
- HTTP → SSE 전환으로 GPT 초안 생성 결과를 문장 단위 청크로 스트리밍, GPT 호출 시간으로 인한 타임아웃 문제 해소

저장소 링크

· <https://github.com/jys0615/Dandelion>

○ 2025.03 - 2025.07

Open Patient-Ψ

오픈 소스 LLM 기반 정신건강 상담 시뮬레이션

Python

PyTorch

1. 프로젝트 소개

오픈소스 LLM을 QLoRA로 파인튜닝해 임상심리 훈련용 AI 환자 페르소나를 구현하는 시뮬레이션 시스템. 공개 한국어 임상 데이터가 존재하지 않는 상황에서 데이터셋 설계·구축부터 모델 학습, 자동 평가 파이프라인까지 연구 전 과정 주도. KCC2025 제1저자 게재(2025.07).

2. 역할

- CBT 이론 기반 학습 데이터셋 설계·구축 전 과정 단독 수행
- QLoRA 4-bit 양자화 파인튜닝 파이프라인 구성 및 하이퍼파라미터 탐색 자동화
- BERTScore + GPT-4.1-mini 이중 자동 평가 파이프라인 설계 및 KCC2025 논문 제1저자 작성

3. 기여한 점

- CCD 구조 기반 7가지 상황 범주 × 3가지 핵심 신념 × 6가지 발화 스타일 조합으로 - 데이터 생성 프레임워크 직접 설계, 총 1,300개 임상대화 샘플 구축

- BitsAndBytesConfig + PEFT 조합으로 QLoRA 4-bit 양자화 파인튜닝 파이프라인 구성, 메모리 사용량 75% 절감 및 단일 GPU에서 3B 모델 학습 가능
- epoch 5단계 × learning rate 5단계 grid search 자동화(50회 실험)로 최적 하이퍼파라미터 도출, BERTScore(F1) 기준 유의미한 성능 향상 확인
- BERTScore(대량 비교) + GPT-4.1-mini Pointwise(accuracy-fidelity 이중 채점) 2단계 자동 평가 파이프라인 설계, Open Patient-ψ(3B)가 GPT-4.1-nano 대비 우위 달성

저장소 링크

· <https://github.com/jys0615/openpatientpsi>

교육이력

○ 2026.04 - 진행중

[LG유플러스] 유레카 SW교육과정 4기 백엔드 개발자 과정

멀티캠퍼스

Java

Spring Boot

MySQL

REST API

Git

GitHub

AWS

LG유플러스 주관 백엔드 개발자 양성 교육과정 (백엔드 대면반). Java 알고리즘, 데이터베이스, Spring 프레임워크, REST API 설계, 클라우드(IaaS/PaaS/SaaS) 등 백엔드 전반을 체계적으로 학습하고, 미니프로젝트 2회 및 프론트엔드 팀과의 최종 융합프로젝트를 수행 (총 1,080시간).

○ 2024.09 - 2025.03

데이터 분석 모델링반(ML1)

BDA 빅데이터분석학회

Python

scikit-learn

Pandas

NumPy

Jupyter

빅데이터분석학회 BDA에서 ML1 3인조 스터디 팀장을 맡아 머신러닝 기초부터 지도·비지도 학습, 모델 평가까지 학습. 단순 이론 습득에 그치지 않고, 학회 내 유료 데이터를 직접 수집·분석해 세션별 이탈 구간을 특정하고 커리큘럼 개선안을 제안. 데이터를 수집하고 가공해 실질적인 인사이트를 도출하는 과정을 직접 경험.

기타사항

○ 2026.03 - 2028.03

SQLD

자격증 | 한국데이터산업진흥원

○ 2025.09 - 2026.02

Google 공식 대학생 커뮤니티

대외활동 | GDGoC KHU

Java Spring과 AIOps 스터디를 매주 진행하며 백엔드와 운영 자동화를 함께 공부했습니다. 핸즈온 실습 중심의 스터디였기 때문에, 이론으로만 알던 개념을 직접 코드로 구현하며 체화하는 경험을 했습니다. Kotlin과 Spring Boot를 활용해 밴드 홍보 플랫폼의 채팅 서버를 개발했고, 발표에서 2위를 기록했습니다. GCP를 사용하며 클라우드 인프라에 대한 이해도도 함께 넓혔습니다.

○ 2025.08 - 2027.08

TOEIC Speaking - 160 (AL)

어학 | YBM

160/AL

○ 2025.03 - 2025.04

경희대학교 제1회 세모톤 최우수상

수상이력 | 경희대학교 SW중심대학사업단

○ 2025.01 - 2025.07

데이터 분석 / 인공지능 동아리 7기

대외활동 | KHUDA

머신러닝 기초부터 NLP까지 스터디를 진행하며 이론을 실제 데이터 분석 문제에 적용하는 연습을 했습니다. 단순히 모델을 돌리는 것에 그치지 않고, 분석 결과가 실제로 의미 있는 인사이트로 이어지는지를 고민하는 습관을 이 시기에 만들었습니다. 공모전 챗봇 프로젝트에도 참여하며 팀 단위의 AI 프로젝트 경험을 쌓았고, 하반기 프로젝트 발표회에서 인기상을 수상했습니다.

○ 2024.09 - 2026.02

교내 러닝 중앙 동아리

대외활동 | KHUMA

○ 2023.01 - 2023.12

제4회 아름다운 사회복무요원 사랑나눔 공모전

수상이력 | 경인지방병무청

○ 2022.08

컴퓨터활용능력1급